

Sistemas de inteligencia computacional para la detección de rayos en imágenes

Daniel Alejandro Rodriguez Suarez*, Sebastián Camilo Salazar Ibañez*

*Universidad Distrital Francisco José de Caldas



Resumen

Este trabajo consiste en la comparación de dos técnicas de inteligencia computacional; lógica difusa y redes neuronales, para la clasificación de patrones en un conjunto de imágenes de rayos de tormentas eléctricas.

Introducción

Para la detección de estos se utilizan redes de alertas de rayos (LWS) que son pocos precisos [1]. Actualmente los sistemas de detección de rayos se han categorizado por centrarse en dos puntos de vista: Análisis de información satelital [3-7] y Análisis de información obtenida en la superficie terrestre [2] y [8-10]. En este trabajo se propone un sistema contador de rayos capturados en imágenes, que se emplea un sistema de lógica difusa que evalúa diferentes estadísticas obtenidas del procesamiento de imágenes realizado.

Plantemianeto del problema

Los sistemas de inteligencia computacional se encargan de clasificar imágenes de rayos de 150x150 píxeles en blanco y negro entres categorías, 0, 1 o 2 rayos presentes. Estas imágenes han sido previamente ajustadas con técnicas de procesamiento de imágenes y en algunos casos recalado para obtener el conjunto de datos.




Figura 1. Ejemplo de imágenes de conjunto de datos.

Modelo de lógica difusa

Este clasifica un conjunto de imágenes de prueba basado en reglas que relacionan datos estadísticos que obtiene de cada imagen (número de objetos, área y excentricidades).




Figura 2. Modelo de lógica difusa.




Figura 3. Reglas de modelo de lógica difusa.

Modelo de redes neuronales

Este clasifica un conjunto de imágenes de prueba basado en las reglas que genera con basa a un entrenamiento hecho con un conjunto de imágenes [11].




Figura 4. Modelo de red neuronal.

Resultados cuantitativos

Para diferentes configuraciones de lógica difusa y redes neuronales se calcularon diferentes valores de interés como son la tasa de aciertos.

Tasa de éxito de implementaciones				
Modelo	tipo de reglas	# filtros	tipo filtro	% de éxito
Lógica difusa	gaussmf	--	--	19,44%
Lógica difusa	gauss2mf	--	--	16,67%
CNNde 10 filtros 3x3	--	10	3x3	58,33%
Redes Neuronales Convolucionales	--	10	5x5	75%
Redes Neuronales Convolucionales	--	20	3x3	66,67%
Redes Neuronales Convolucionales	--	20	5x5	66,67%
Redes Neuronales Convolucionales	--	30	3x3	75%
Redes Neuronales Convolucionales	--	30	5x5	41,67%

Tabla 1. Tasa de aciertos de implmentaciones.




Figura 5. Resultados de tasa de aciertos de implementaciones.

Resultados cualitativos

El mejor desempeño se obtuvo con la configuración de red neuronal con capas convolucionales de 10 filtros 5x5. El entrenamiento se hizo en 100 epocas cada una con 100 hiteraciones. Adicionalmente solo se presentarán 3 casos en los que el resultado de la validación no fue el esperado.




Figura 6. Desempeño de entrenamiento red neuronal.




Figura 7. Errores con imagenes de validación.

Conclusiones

Para aplicaciones de reconocimiento de patrones en imágenes las soluciones que usan redes neuronales superan con creces las soluciones con lógica difusa, en la tabla 1 se puede observar que la diferencia entre las tasas de éxito del primer algoritmo de lógica difusa y el mejor resultado de redes neuronales es de 55.56%. Para este ejercicio se pudo apreciar que un aumento en el número de filtros en las capas no aumenta la tasa de éxito, y que aunque tipo de filtro si influye, con las pruebas realizadas no es posible determinar el cómo lo hace. Adicionalmente si bien es cierto que teóricamente es posible ajustar los sistemas de lógica difusa para la clasificación de imágenes de forma manual, el acercamiento usando redes neuronales es mas recomendable para grandes volúmenes de datos porque muchas veces los algoritmos de entrenamiento se encargan de optimizar el resultado, sacrificando tiempo de computación pero ahorrando tiempo humano, que en la mayoría de los casos es más valioso.

Referencias

[1] WangG, Hyun W, Kil G, Park D, Wook S. (2019). "An Intelligent Lightning Warning System Based on Electromagnetic Field and Neural Network". Energies 12, no. 7: 1275. <https://doi.org/10.3390/en12071275>

[2] Mialdea I, Segura J, Felici Santiago, Garcia M, Alcaraz J, Navarro E. (2019). "Development of a Low-Cost IoT system for Lightning Strike Detection and Location". Electronics 8, no. 12: 1512. <https://doi.org/10.3390/electronics8121512>

[3] Umar A, Yoshiya K, Shoya M, Mitsunori O, Yoshitaka. (2019). "Automatic Detection of Lightning Whistlers Observed by the Plasma Wave Experiment Onboard the Arase Satellite Using the OpenCV Library". remote Sens. 11, no. 15: 1785. <https://doi.org/10.3390/rs11151785>

[4] Kimov P, Khrenov B, Kaznacheeva M, Garipov G, Panasyuk M, Petrov V, Sharakin S, Shirokov A, Yashin I, Zotov M, Grebenyuk V, Grinyuk A, Lavrova M, Tkachenko A, Tkachev L, Botvinko A, Saprykin O, Puchkov A, Senkovsky A. (2019). "Remote Sensing of the Atmosphere by the Ultraviolet Detector TUS Onboard the Lomonosov Satellite". Remote Sens. 11, no. 20: 2449. <https://doi.org/10.3390/rs11202449>

[5] Pio L, Paziienza L, Mascitelli A, Tiberia A, Dietrich S. (2020). "A Combined IR-GPS Satellite Analysis for Potential Applications in Detecting and Predicting Lightning Activity". Remote Sens. 12, no. 6: 1031. <https://doi.org/10.3390/rs12061031>

[6] Alammar A, Alkahtani A, Riduan M, Noman F, Riza M, Haziq M, Ali S, Salih A, Kawasaki Z, Agelidis V. (2020). "Kalman Filter and Wavelet Cross-Correlation for VHF Broadband Interferometer Lightning Mapping". Appl. Sci. 10, no. 12: 4238. <https://doi.org/10.3390/app10124238>

[7] Hyangsun H, Sanggyun L, Jungcho I, Miae K, Myong-In L, Myoung A, Sung-Rae C. (2015). "Detection of Convective Initiation Using Meteorological Imager Onboard Communication, Ocean, and Meteorological Satellite Based on Machine Learning Approaches". Remote Sens. 7, no. 7: 9184-9204. <https://doi.org/10.3390/rs70709184>

[8] Yusop N, Riduan M, Abdullah M, Riza M, Ali S, Suparta W, Gulisano A, Cooray V. (2019). "Seasonal Analysis of Cloud-To-Ground Lightning Flash Activity in the Western Antarctica". Atmosphere 10, no. 12: 744. <https://doi.org/10.3390/atmos1012744>

[9] Price C. (2008). "Lightning Sensors for Observing, Tracking and Nowcasting Severe Weather". Sensors 8, no. 1: 157-170. <https://doi.org/10.3390/s8010157>

[10] Kossowski J, Matuszewski L. (2021). "Non-Real-Time Wireless System for LightningEffect Measurements". Appl. Sci. 11, no. 9: 4204. <https://doi.org/10.3390/app11094204>

[11] Coding Like Mad. (2020). "Convolutional Neural Network in Matlab For Object Recognition - Matlab Tutorial". Recuperado de: <https://youtu.be/K9YyX-q32k>